

Deep Learning para problemas de información cuántica

Defensa de Tesis Doctoral — *demo Beamer + metropolis*

Antonio Guerra

July 7, 2026

Universidad de Concepción

1. **Background** — información cuántica y deep learning
2. **Estado del arte** — combinando ambos mundos
3. **Contribución 1** — interpolación de unitarias (PINNs)
4. **Contribución 2** — reconstrucción desde marginales (CDAE + MIO)
5. **Conclusiones** y trabajo futuro

Idea rectora

Incrustar la física conocida en el aprendizaje (*physics-informed*) extiende los métodos clásicos a problemas cuya complejidad crece como 2^N .

Background: la barrera exponencial

Un estado de N qubits vive en un espacio de dimensión 2^N :

$$\rho(t) = U(t) \rho_0 U^\dagger(t), \quad i\dot{U} = H(t) U.$$

- Construir/exponenciar $U(t)$ escala como $\mathcal{O}(2^{3N})$.
- Con $H(t)$ dependiente del tiempo no hay e^{-iHt} cerrado.

Physics-informed learning


La física entra por la *loss*: la red aprende solo soluciones físicamente admisibles (unitaridad, positividad, marginales).

Contribución 1 — Interpolación de unitarias con PINNs

Dada $U(t_i)$ en tiempos muestreados, interpolamos $U(t)$ en todo $[0, T]$ **sin conocer el Hamiltoniano**.

$$F(U, U_\theta) = \left| \frac{1}{d} \text{Tr} [U^\dagger U_\theta] \right|^2$$

- Fidelidad ≈ 0.99 (2–8 qubits)
- Speedups $8.9\times$ – $19.3\times$ vs. geodésica



Dos problemas duros, un mismo patrón:
la física en la loss convierte lo intratable en aprendible.