

Deep Learning en Información Cuántica — Mapa del Estado del Arte

Julio 2026

1. Neural Quantum States (NQS)

Qué hace. Representa un estado cuántico $\psi_\theta(x)$ mediante una red neuronal, en vez de una tabla exponencial de amplitudes. Se usa para encontrar estados base, estados excitados, estados térmicos, evolución temporal y propiedades espectrales.

Cómo lo hace. Dado un Hamiltoniano $\hat{H}$ (input, no datos), se optimiza θ minimizando la energía variacional $\langle \hat{H} \rangle$ vía Monte Carlo (VMC), con muestras generadas por el propio modelo ($x \sim |\psi_\theta|^2$). El gradiente natural (stochastic reconfiguration) usa la métrica de Fubini-Study. Para dinámica se usa t-VMC (proyección TDVP).

Limitaciones. La dificultad no depende del tamaño del sistema sino del entrelazamiento y la estructura de signos del estado — sistemas frustrados y fermiónicos generalizan mal. La optimización de la fase/signo es más difícil que la de amplitudes. t-VMC es mal condicionado (redundancia gauge en la métrica QGT), requiriendo regularización que introduce sesgo. Sin certificado de optimalidad más allá de la cota variacional y la varianza de energía.

Paper que lo originó: Carleo & Troyer, “Solving the quantum many-body problem with artificial neural networks”, *Science* 355, 602 (2017).

Mejor a la fecha: Rende et al., “A hidden variational formulation of the density matrix for finite temperature calculations” o el desarrollo de *Foundation Neural-Network Quantum States* — un solo ansatz entrenado para múltiples Hamiltonianos (*Nat. Commun.* 2025), junto con Chen & Heyl, “Empowering deep neural quantum states through efficient optimization” (*Nat. Phys.* 2024), que resolvió el cuello de botella de escalar la optimización a 10^5 - 10^6 parámetros.

Para leer en diagonal: 1. Carleo & Troyer, *Science* 355, 602 (2017) — el fundacional. 2. Lange, Van de Walle, Abol-Fotouh et al., “Architectures and accuracy of artificial neural network approaches for quantum many-body systems”, *Quantum Sci. Technol.* (2024, arXiv 2402.09402) — review que mapea todo el campo.

2. Tomografía y estimación de estados

Qué hace. Reconstruye la matriz densidad ρ de un estado a partir de datos de medida experimentales.

Cómo lo hace. Dos paradigmas distintos: - **Familia A (generativa):** la red es el estado — se entrena por máxima verosimilitud contra las frecuencias medidas de un estado concreto (RBMs, POVM generativos). - **Familia B (supervisada):** la red es

un algoritmo — se entrena offline con pares (frecuencias, ρ) sintéticos, y en inferencia hace un solo forward pass sobre datos nuevos.

Limitaciones. Familia B depende de la distribución de estados usada para generar el dataset sintético — generaliza mal fuera de ella. Ningún método hace tomografía completa de sistemas grandes (limitación información-teórica, no solo de arquitectura). Ausencia casi total de cuantificación de incertidumbre, a diferencia de MLE clásica. El giro de *classical shadows* (Huang, Kueng & Preskill) cuestiona si reconstruir ρ completo es siquiera necesario cuando solo se buscan observables.

Paper que lo originó: Torlai, Mazzola, Carrasquilla, Troyer, Melko & Carleo, “Neural-network quantum state tomography”, *Nat. Phys.* 14, 447 (2018).

Mejor a la fecha: Huang, Kueng, Torlai, Albert & Preskill, “Provably efficient machine learning for quantum many-body problems”, *Science* 377, eabk3333 (2022) — el único resultado del área con ventaja demostrada bajo supuestos de complejidad computacional, extendido por Lewis et al. (*Nat. Commun.* 15, 895, 2024) con requisitos de datos exponencialmente reducidos.

Para leer en diagonal: 1. Torlai et al., *Nat. Phys.* 14, 447 (2018) — el fundacional. 2. Huang, Kueng, Torlai, Albert & Preskill, *Science* 377, eabk3333 (2022) — el giro conceptual hacia predicción de propiedades sin reconstrucción completa.

3. Corrección de errores cuánticos (decodificación)

Qué hace. Dado un síndrome de medida en un código estabilizador (ej. surface code), predice qué corrección física aplicar.

Cómo lo hace. Clasificación supervisada: síndrome $\rightarrow$ corrección, con etiquetas generadas por simulación (se conoce el error inyectado). Arquitecturas recientes usan transformers recurrentes procesando lecturas “soft” (I/Q) en vez de bits binarizados, con pre-entrenamiento en datos simulados y fine-tuning en datos reales del dispositivo.

Limitaciones. Caja negra sin garantías demostrables (a diferencia de MWPM). Latencia: la atención estándar escala $\mathcal{O}(d^4)$ con la distancia del código, insuficiente para tiempo real sin arquitecturas alternativas (Mamba, ventanas paralelas) o hardware dedicado (FPGA). Dependencia fuerte del dispositivo específico de calibración. El cuello de botella último sigue siendo la fidelidad física del qubit, no el decoder.

Paper que lo originó: Torlai & Melko, “Neural Decoder for Topological Codes”, *PRL* 119, 030501 (2017).

Mejor a la fecha: Bausch et al., “Learning high-accuracy error decoding for quantum processors” (AlphaQubit), *Nature* 634 (2024) — supera a decoders clásicos con datos reales del procesador Sycamore; su sucesor AlphaQubit 2 (arXiv 2512.07737, 2025) generaliza a través de múltiples distancias de código y a color codes.

Para leer en diagonal: 1. Torlai & Melko, *PRL* 119, 030501 (2017) — el fundacional. 2. Bausch et al., “Learning high-accuracy error decoding for quantum processors”, *Nature* 634 (2024) — AlphaQubit.

4. Hamiltonian Learning

Qué hace. Infiere los parámetros (o la forma) de un Hamiltoniano desconocido a partir de datos de medida u observables dinámicos.

Cómo lo hace. Es el problema inverso de NQS. La rama no-neuronal usa relaciones lineales entre observables y conmutadores (Bairey-Arad-Lindner) con garantías de muestra óptimas (Heisenberg-limited). La rama de deep learning incorpora la ecuación de Schrödinger como restricción blanda en la función de pérdida (iPINN-HL) o usa neural ODEs para ajustar la dinámica completa contra trayectorias observadas, siendo más robusta a ruido no modelado y sistemas abiertos.

Limitaciones. Compite contra un estándar teórico muy alto (escalamiento óptimo ya demostrado sin redes neuronales) — el deep learning debe justificarse en robustez o flexibilidad, no en eficiencia de muestra pura. Problema de identificabilidad: distintos $\hat{H}$ pueden producir estadísticas indistinguibles con datos finitos. Casi todo el campo asume conocida la estructura (localidad) del Hamiltoniano y solo estima coeficientes.

Paper que lo originó (no neuronal, pero fundacional del problema): Bairey, Arad & Lindner, “Learning a local Hamiltonian from local measurements”, *PRL* 122, 020504 (2019).

Mejor a la fecha: Sanders et al., “Hamiltonian learning via inverse physics-informed neural networks” (iPINN-HL), *Phys. Rev. Research* 7, 043137 (2025) — el más cercano metodológicamente a PINNs, validado en cadenas de espín y calibración de compuertas cross-resonance.

Para leer en diagonal: 1. Bairey, Arad & Lindner, *PRL* 122, 020504 (2019) — el problema bien planteado, sin redes. 2. Sanders et al., *Phys. Rev. Research* 7, 043137 (2025) — iPINN-HL.

5. Control cuántico y compilación con RL

Qué hace. Dos problemas relacionados: (a) encontrar el pulso analógico que implementa un gate o prepara un estado con máxima fidelidad; (b) encontrar la secuencia de compuertas discretas que implementa un circuito con mínima profundidad/costo.

Cómo lo hace. Reinforcement learning — un agente propone acciones (formas de pulso o compuertas), la recompensa es la fidelidad lograda contra el objetivo (simulada o medida en hardware real). No requiere modelo diferenciable del sistema, lo que lo hace robusto cuando el ruido del hardware no está bien caracterizado.

Limitaciones. Costoso en muestras — cada episodio requiere simular o ejecutar la dinámica completa. Brecha sim-to-real: las ganancias espectaculares en simulación se reducen en hardware real. Benchmarks fragmentados entre papers, dificultando comparación directa. Comparación contra baselines clásicos (GRAPE, síntesis exacta) no siempre bien ajustados.

Paper que lo originó: Bukov, Day et al., “Reinforcement learning in different phases of quantum control”, *PRX* 8, 031086 (2018).

Mejor a la fecha: Ruiz et al., “Quantum circuit optimization with AlphaTensor”, *Nat. Mach. Intell.* 7, 374 (2025) — mismo linaje que el resultado de multiplicación de matrices de *Nature* 2022, aplicado a reducir T-count con desempeño de estado del arte; en control físico, Baum et al. (*PRX Quantum* 2, 040324, 2021) sigue siendo la referencia por validarse en hardware superconductor real.

Para leer en diagonal: 1. Bukov, Day et al., *PRX* 8, 031086 (2018) — el fundacional. 2. Ruiz et al., “Quantum circuit optimization with AlphaTensor”, *Nat. Mach. Intell.* 7, 374 (2025).

6. Detección de entrelazamiento y clasificación de fases

Qué hace. Decide si un estado está entrelazado, cuantifica cuánto, o clasifica en qué fase de materia se encuentra un sistema.

Cómo lo hace. Mayormente supervisado: se generan estados con separabilidad o fase conocida por construcción (mezclas de productos para separables; barridos de un Hamiltoniano parametrizado para fases), y se entrena un clasificador (CNN, DNN) sobre datos de medida o sobre la función de onda simulada.

Limitaciones. Decidir separabilidad en el caso general es NP-duro — el dataset de entrenamiento solo cubre casos donde la etiqueta es fácil de construir, no el problema completo. Generalización pobre fuera de esa distribución de entrenamiento. La mayoría de los resultados son en simulación; validación experimental real sigue siendo escasa.

Paper que lo originó: Deng, Li & Das Sarma, “Machine learning topological states”, *Phys. Rev. B* 96, 195145 (2017).

Mejor a la fecha: trabajo de detección de entrelazamiento desde medidas incompletas con validación experimental fotónica real (*Science Advances*) — se distingue del resto del área por cerrar el ciclo con el laboratorio en vez de quedarse en simulación.

Para leer en diagonal: 1. Deng, Li & Das Sarma, *Phys. Rev. B* 96, 195145 (2017) — el fundacional para clasificación de fases. 2. Trabajo de detección de entrelazamiento desde medidas incompletas validado experimentalmente (*Science Advances*) — mejor validación real del área.

7. Diseño de experimentos y modelos generativos

Qué hace. Genera el diseño de un experimento físico (montaje óptico, arreglo de componentes) que produce una propiedad cuántica objetivo — por ejemplo, alto entrelazamiento — en vez de analizar un experimento ya realizado.

Cómo lo hace. Modelos generativos (VAEs) o búsqueda simbólica que aprenden una representación del espacio de configuraciones experimentales posibles y navegan ese espacio optimizando una métrica objetivo.

Limitaciones. El espacio de diseño está restringido a priori al vocabulario de componentes/operaciones que el modelo conoce — no descubre física fuera de ese repertorio. Interpretar por qué un diseño generado funciona suele requerir análisis manual posterior. Validación experimental de los diseños propuestos sigue siendo escasa frente al volumen de propuestas generadas in silico.

Paper que lo originó: Krenn, Malik, Fickler, Lapkiewicz & Zeilinger, “Automated Search for new Quantum Experiments”, *PRL* 116, 090405 (2016) — MELVIN, búsqueda simbólica, precursor conceptual del campo.

Mejor a la fecha: QOVAE — variational autoencoder que aprende representaciones interpretables de experimentos de óptica cuántica y genera setups nuevos para estados de alto entrelazamiento, extendiendo la línea de Krenn/Aspuru-Guzik con deep learning generativo propiamente dicho.

Para leer en diagonal: 1. Krenn, Malik, Fickler, Lapkiewicz & Zeilinger, *PRL* 116, 090405 (2016) — el fundacional (MELVIN). 2. QOVAE (paper del VAE para diseño de experimentos de óptica cuántica) — la versión con deep learning generativo.

Resumen de trayectoria del campo

Área	Paradigma dominante	Estado de madurez
1. NQS	Variacional (VMC)	Activo, compitiendo en problemas abiertos (Hubbard, spin liquids)
2. Tomografía	Supervisado / MLE neuronal	Maduro, con giro reciente hacia shadow tomography
3. Corrección de errores	Supervisado	El más cercano a producción (AlphaQubit, FPGA)
4. Hamiltonian learning	Híbrido variacional-supervisado	Compite contra teoría con garantías óptimas
5. Control y compilación	Reinforcement learning	Maduro en control, activo en compilación
6. Entrelazamiento/fases	Supervisado	Limitado por NP-dureza del problema general
7. Diseño de experimentos	Generativo	Emergente, poca validación experimental