

Métodos de redes neuronales para el estudio de sistemas físicos en información cuántica

Antonio Guerra

Departamento de Física, Universidad de Concepción
Instituto Milenio de Investigación en Óptica

Agosto 2026

Estructura de la presentación

- 1 Información cuántica
- 2 Deep learning
- 3 Deep learning en información cuántica
- 4 Trabajo I: reconstrucción desde marginales cuánticos
- 5 Trabajo II: interpolación de unitarias
- 6 Trabajos futuros

Estados cuánticos y matriz densidad

Un sistema cuántico queda descrito por un operador densidad $\rho \in \mathcal{L}(\mathcal{H})$ que satisface

$$\rho = \rho^\dagger, \quad \rho \geq 0, \quad \text{Tr}(\rho) = 1.$$

Estados cuánticos y matriz densidad

Un sistema cuántico queda descrito por un operador densidad $\rho \in \mathcal{L}(\mathcal{H})$ que satisface

$$\rho = \rho^\dagger, \quad \rho \geq 0, \quad \text{Tr}(\rho) = 1.$$

- Estado puro: $\text{Tr}(\rho^2) = 1$, equivalentemente $\rho = |\psi\rangle \langle \psi|$.
- Estado mixto: $\text{Tr}(\rho^2) < 1$.

Estados cuánticos y matriz densidad

Un sistema cuántico queda descrito por un operador densidad $\rho \in \mathcal{L}(\mathcal{H})$ que satisface

$$\rho = \rho^\dagger, \quad \rho \geq 0, \quad \text{Tr}(\rho) = 1.$$

- Estado puro: $\text{Tr}(\rho^2) = 1$, equivalentemente $\rho = |\psi\rangle\langle\psi|$.
- Estado mixto: $\text{Tr}(\rho^2) < 1$.

Por qué importa aquí

Las tres condiciones anteriores definen una variedad no trivial dentro del espacio de matrices complejas. Una red neuronal que produzca matrices arbitrarias no genera estados físicos. Esta restricción es el punto de partida del primer trabajo.

Sistemas compuestos y trazas parciales

Para un sistema de N partes, $\mathcal{H} = \mathcal{H}_1 \otimes \cdots \otimes \mathcal{H}_N$, con dimensión $\dim \mathcal{H} = \prod_i d_i$.

Sistemas compuestos y trazas parciales

Para un sistema de N partes, $\mathcal{H} = \mathcal{H}_1 \otimes \cdots \otimes \mathcal{H}_N$, con dimensión $\dim \mathcal{H} = \prod_i d_i$.

El estado de un subconjunto S de partes se obtiene por traza parcial sobre el complemento,

$$\rho_S = \text{Tr}_{\bar{S}}(\rho).$$

Sistemas compuestos y trazas parciales

Para un sistema de N partes, $\mathcal{H} = \mathcal{H}_1 \otimes \cdots \otimes \mathcal{H}_N$, con dimensión $\dim \mathcal{H} = \prod_i d_i$.

El estado de un subconjunto S de partes se obtiene por traza parcial sobre el complemento,

$$\rho_S = \text{Tr}_{\bar{S}}(\rho).$$

- ρ_S es el *marginal* asociado a S .
- Los marginales son accesibles experimentalmente con muchas menos mediciones que ρ completo.
- La reconstrucción de ρ a partir de marginales es el problema del trabajo I.

El costo exponencial

La dimensión del espacio de Hilbert crece como d^N . Para N qubits:

N	$\dim \mathcal{H}$	parámetros reales de ρ
2	4	15
4	16	255
6	64	4 095
8	256	65 535

El costo exponencial

La dimensión del espacio de Hilbert crece como d^N . Para N qubits:

N	$\dim \mathcal{H}$	parámetros reales de ρ
2	4	15
4	16	255
6	64	4 095
8	256	65 535

Este escalamiento es el obstáculo común a la tomografía, la simulación de la dinámica y la certificación de recursos cuánticos. Es también lo que motiva el uso de representaciones aprendidas.

La evolución de un sistema cerrado obedece

$$i\hbar \frac{d}{dt} |\psi(t)\rangle = \hat{H}(t) |\psi(t)\rangle, \quad |\psi(t)\rangle = \hat{U}(t) |\psi(0)\rangle.$$

La evolución de un sistema cerrado obedece

$$i\hbar \frac{d}{dt} |\psi(t)\rangle = \hat{H}(t) |\psi(t)\rangle, \quad |\psi(t)\rangle = \hat{U}(t) |\psi(0)\rangle.$$

Para $\hat{H}$ independiente del tiempo, $\hat{U}(t) = e^{-i\hat{H}t/\hbar}$.

La evolución de un sistema cerrado obedece

$$i\hbar \frac{d}{dt} |\psi(t)\rangle = \hat{H}(t) |\psi(t)\rangle, \quad |\psi(t)\rangle = \hat{U}(t) |\psi(0)\rangle.$$

Para $\hat{H}$ independiente del tiempo, $\hat{U}(t) = e^{-i\hat{H}t/\hbar}$.

El caso dependiente del tiempo

Si $[\hat{H}(t_1), \hat{H}(t_2)] \neq 0$, la exponencial ordenada

$$\hat{U}(t) = \mathcal{T} \exp \left(-\frac{i}{\hbar} \int_0^t \hat{H}(t') dt' \right)$$

no admite forma cerrada. Se requieren métodos de aproximación.

Se escribe $\hat{U}(t) = \exp(\Omega(t))$ con $\Omega = \sum_k \Omega_k$,

$$\Omega_1(t) = -\frac{i}{\hbar} \int_0^t \hat{H}(t_1) dt_1,$$

$$\Omega_2(t) = -\frac{1}{2\hbar^2} \int_0^t dt_1 \int_0^{t_1} dt_2 [\hat{H}(t_1), \hat{H}(t_2)],$$

$$\Omega_3(t) = \dots$$

Se escribe $\hat{U}(t) = \exp(\Omega(t))$ con $\Omega = \sum_k \Omega_k$,

$$\Omega_1(t) = -\frac{i}{\hbar} \int_0^t \hat{H}(t_1) dt_1,$$

$$\Omega_2(t) = -\frac{1}{2\hbar^2} \int_0^t dt_1 \int_0^{t_1} dt_2 [\hat{H}(t_1), \hat{H}(t_2)],$$

$$\Omega_3(t) = \dots$$

- Preserva unitariedad a cualquier orden de truncamiento.
- El costo por término crece rápidamente con el orden.
- Requiere evaluar conmutadores anidados en cada paso temporal.

Descomposición de Trotter

Para $\hat{H} = \hat{H}_A + \hat{H}_B$ con $[\hat{H}_A, \hat{H}_B] \neq 0$,

$$e^{-i\hat{H}\Delta t} = e^{-i\hat{H}_A\Delta t} e^{-i\hat{H}_B\Delta t} + \mathcal{O}(\Delta t^2),$$

y la evolución total se obtiene concatenando $n = t/\Delta t$ pasos.

Descomposición de Trotter

Para $\hat{H} = \hat{H}_A + \hat{H}_B$ con $[\hat{H}_A, \hat{H}_B] \neq 0$,

$$e^{-i\hat{H}\Delta t} = e^{-i\hat{H}_A\Delta t} e^{-i\hat{H}_B\Delta t} + \mathcal{O}(\Delta t^2),$$

y la evolución total se obtiene concatenando $n = t/\Delta t$ pasos.

- El error se controla reduciendo Δt , a costa de más pasos.
- Es el método estándar en simulación de circuitos cuánticos.
- Junto con Magnus, define la línea base contra la cual se compara el trabajo II.

Los dos problemas que aborda esta tesis se enuncian ahora con precisión.

Problema I

Dado un conjunto incompleto de marginales $\{\rho_S\}$, reconstruir un operador densidad ρ compatible con ellos, garantizando hermiticidad, positividad y traza unitaria.

Resumen de la sección

Los dos problemas que aborda esta tesis se enuncian ahora con precisión.

Problema I

Dado un conjunto incompleto de marginales $\{\rho_S\}$, reconstruir un operador densidad ρ compatible con ellos, garantizando hermiticidad, positividad y traza unitaria.

Problema II

Dada una familia de unitarias $\hat{U}(t)$ generada por un Hamiltoniano dependiente del tiempo, obtener una representación continua en t que reproduzca la dinámica a un costo computacional menor que Magnus o Trotter.

Capas totalmente conectadas

Una red *feedforward* compone transformaciones afines con no linealidades,

$$a_j^{(l)} = f \left(\sum_i w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right).$$

Una red *feedforward* compone transformaciones afines con no linealidades,

$$a_j^{(l)} = f \left(\sum_i w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right).$$

- Los parámetros $\theta = \{w, b\}$ se ajustan minimizando una función de costo.
- El teorema de aproximación universal garantiza expresividad, pero no dice cuántos parámetros se necesitan.
- En la práctica, la estructura del problema determina qué arquitectura es eficiente.

Una capa convolucional aplica un núcleo k sobre el mapa de entrada a ,

$$\tilde{a}(x, y) = \sum_{\tilde{x}, \tilde{y}} \sum_i a_i(\tilde{x}, \tilde{y}) k_i(x - \tilde{x}, y - \tilde{y}).$$

Una capa convolucional aplica un núcleo k sobre el mapa de entrada a ,

$$\tilde{a}(x, y) = \sum_{\tilde{x}, \tilde{y}} \sum_i a_i(\tilde{x}, \tilde{y}) k_i(x - \tilde{x}, y - \tilde{y}).$$

- Pesos compartidos: invariancia traslacional y menos parámetros que una capa densa equivalente.
- Estructura local: adecuada para datos con correlaciones de vecindad.
- Una matriz densidad admite una representación de dos canales, parte real y parte imaginaria, análoga a una imagen.

Un autoencoder compone un codificador E y un decodificador D ,

$$\rho \longmapsto \hat{\rho} = D_{\theta}(E(\rho)),$$

entrenados para minimizar el error de reconstrucción.

Un autoencoder compone un codificador E y un decodificador D ,

$$\rho \mapsto \hat{\rho} = D_{\theta}(E(\rho)),$$

entrenados para minimizar el error de reconstrucción.

- El cuello de botella fuerza una representación comprimida de la variedad de datos.
- En su versión *denoising*, la entrada se corrompe deliberadamente y la red aprende a recuperar la señal limpia.
- Esta es la arquitectura del trabajo I.

Entrenamiento y retropropagación

El ajuste de θ procede por descenso de gradiente,

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(\theta),$$

con $\nabla_{\theta} \mathcal{L}$ calculado por retropropagación, esto es, aplicación sistemática de la regla de la cadena sobre el grafo de cómputo.

Entrenamiento y retropropagación

El ajuste de θ procede por descenso de gradiente,

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(\theta),$$

con $\nabla_{\theta} \mathcal{L}$ calculado por retropropagación, esto es, aplicación sistemática de la regla de la cadena sobre el grafo de cómputo.

Diferenciación automática

El mismo mecanismo permite obtener derivadas de la salida respecto de las *entradas*, no solo respecto de los parámetros. Si la entrada es el tiempo, se obtiene ∂_t de la salida de forma exacta y sin discretizar. Esta propiedad es la que hace posible el trabajo II.

Una PINN incorpora la ecuación gobernante directamente en la función de costo,

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda \mathcal{L}_{\text{física}}, \quad \mathcal{L}_{\text{física}} = \sum_j \|\mathcal{D}[u_{\theta}(t_j)]\|^2.$$

Una PINN incorpora la ecuación gobernante directamente en la función de costo,

$$\mathcal{L} = \mathcal{L}_{\text{datos}} + \lambda \mathcal{L}_{\text{física}}, \quad \mathcal{L}_{\text{física}} = \sum_j \|\mathcal{D}[u_{\theta}(t_j)]\|^2.$$

- El residuo se evalúa en puntos de colocación arbitrarios, sin necesidad de datos en ellos.
- La solución aprendida es continua en t y diferenciable.
- El costo de evaluación es independiente del instante consultado.

Área	Objetivo	Referencias
Neural quantum states	Representar $ \psi\rangle$ variacionalmente	Carleo y Troyer 2017; Lange <i>et al.</i> 2024
Tomografía	Reconstruir el estado de datos de medición	Torlai <i>et al.</i> 2018; Huang <i>et al.</i> 2022
Corrección de errores	Decodificar síndromes	Torlai y Melko 2017; Bausch <i>et al.</i> 2024
Hamiltonian learning	Identificar $\hat{H}$ desde datos	Bairey <i>et al.</i> 2019; Liu y Wang 2025
Control cuántico	Diseñar pulsos de control	Bukov <i>et al.</i> 2018; Norambuena <i>et al.</i> 2024
Fases y orden topológico	Clasificar fases de la materia	Deng <i>et al.</i> 2017
Recursos cuánticos	Detectar entrelazamiento y discordia	Muñoz-Mellado <i>et al.</i> 2026

Neural quantum states

La función de onda se parametriza mediante una red, $\psi_\theta(\sigma) = \sqrt{p_\theta(\sigma)} e^{i\phi_\theta(\sigma)}$, y los observables se estiman por Monte Carlo,

$$\langle \hat{O} \rangle = \sum_{\sigma} P_{\theta}(\sigma) O_{\theta}^{\text{loc}}(\sigma), \quad O_{\theta}^{\text{loc}}(\sigma) = \sum_{\sigma'} \frac{\psi_{\theta}(\sigma')}{\psi_{\theta}(\sigma)} \langle \sigma | \hat{O} | \sigma' \rangle.$$

Neural quantum states

La función de onda se parametriza mediante una red, $\psi_{\theta}(\sigma) = \sqrt{p_{\theta}(\sigma)} e^{i\phi_{\theta}(\sigma)}$, y los observables se estiman por Monte Carlo,

$$\langle \hat{O} \rangle = \sum_{\sigma} P_{\theta}(\sigma) O_{\theta}^{\text{loc}}(\sigma), \quad O_{\theta}^{\text{loc}}(\sigma) = \sum_{\sigma'} \frac{\psi_{\theta}(\sigma')}{\psi_{\theta}(\sigma)} \langle \sigma | \hat{O} | \sigma' \rangle.$$

- El vector de estado completo nunca se construye. Solo se evalúa la red en las configuraciones muestreadas.
- El entrenamiento se guía por el Hamiltoniano, sin datos externos.
- Establece el patrón que reaparece en el resto del área: representación aprendida más estimación estocástica.

Torlai *et al.* (2018) reconstruyen $|\psi\rangle$ minimizando la divergencia de Kullback-Leibler entre la distribución de mediciones y las amplitudes de la red, sumada sobre varias bases,

$$\Xi(\kappa) = \sum_b \text{KL}[P_b \parallel |\psi_\kappa|^2] .$$

Torlai *et al.* (2018) reconstruyen $|\psi\rangle$ minimizando la divergencia de Kullback-Leibler entre la distribución de mediciones y las amplitudes de la red, sumada sobre varias bases,

$$\Xi(\kappa) = \sum_b \text{KL}[P_b \parallel |\psi_\kappa|^2] .$$

Limitación relevante para esta tesis

La parametrización $\psi = \sqrt{p} e^{i\phi}$ impone pureza por construcción. El caso mixto, que es el experimentalmente realista, exige imponer hermiticidad, positividad y traza de forma explícita.

Dos enfoques representativos.

- Bairey *et al.*: para ρ estacionario, $\langle i[\hat{A}, \hat{H}] \rangle = 0$ define un sistema lineal $K\vec{c} = 0$, y los coeficientes se obtienen del vector singular más bajo de K .

Dos enfoques representativos.

- Bairey *et al.*: para ρ estacionario, $\langle i[\hat{A}, \hat{H}] \rangle = 0$ define un sistema lineal $K\vec{c} = 0$, y los coeficientes se obtienen del vector singular más bajo de K .
- Liu y Wang: el problema se plantea como problema inverso de la ecuación de Schrödinger, con los coeficientes de $\hat{H}$ como parámetros entrenables junto con los pesos de la red.

Dos enfoques representativos.

- Bairey *et al.*: para ρ estacionario, $\langle i[\hat{A}, \hat{H}] \rangle = 0$ define un sistema lineal $K\vec{c} = 0$, y los coeficientes se obtienen del vector singular más bajo de K .
- Liu y Wang: el problema se plantea como problema inverso de la ecuación de Schrödinger, con los coeficientes de $\hat{H}$ como parámetros entrenables junto con los pesos de la red.

Diferencia con el trabajo II

Ambos apuntan a identificar los parámetros del Hamiltoniano real, y miden éxito como error paramétrico. El trabajo II apunta a caracterizar la dinámica, y mide éxito como fidelidad de la evolución reproducida.

Dónde se ubican las contribuciones de esta tesis

Trabajo I, reconstrucción de matrices densidad

La literatura de tomografía con redes se ha concentrado en estados puros. El trabajo I opera sobre estados mixtos, imponiendo las condiciones de positividad y normalización mediante un operador construido para ese fin.

Dónde se ubican las contribuciones de esta tesis

Trabajo I, reconstrucción de matrices densidad

La literatura de tomografía con redes se ha concentrado en estados puros. El trabajo I opera sobre estados mixtos, imponiendo las condiciones de positividad y normalización mediante un operador construido para ese fin.

Trabajo II, interpolación de unitarias

La literatura de aprendizaje de Hamiltonianos busca identificar parámetros bajo un ansatz conocido. El trabajo II construye un generador efectivo validado por fidelidad dinámica, sin suponer la forma funcional de la dependencia temporal.

Planteamiento del problema

Se dispone de un subconjunto de marginales $\{\rho_S\}_{S \in \mathcal{S}}$ obtenidos experimentalmente. Se busca ρ tal que

$$\text{Tr}_{\bar{S}}(\rho) = \rho_S \quad \forall S \in \mathcal{S}, \quad \rho = \rho^\dagger, \quad \rho \geq 0, \quad \text{Tr}(\rho) = 1.$$

Planteamiento del problema

Se dispone de un subconjunto de marginales $\{\rho_S\}_{S \in \mathcal{S}}$ obtenidos experimentalmente. Se busca ρ tal que

$$\text{Tr}_{\bar{S}}(\rho) = \rho_S \quad \forall S \in \mathcal{S}, \quad \rho = \rho^\dagger, \quad \rho \geq 0, \quad \text{Tr}(\rho) = 1.$$

- Cuando $\mathcal{S}$ no es informacionalmente completo, la solución no es única.
- Los métodos convencionales requieren optimización convexa con restricciones, costosa al crecer N .
- Los marginales de bajo orden son mucho más baratos de medir que ρ completo.

- 1 Codificar ρ como un arreglo de dos canales, parte real y parte imaginaria.

- 1 Codificar ρ como un arreglo de dos canales, parte real y parte imaginaria.
- 2 Entrenar un autoencoder convolucional *denoising* para recuperar ρ a partir de una versión degradada, construida desde información marginal incompleta.

- 1 Codificar ρ como un arreglo de dos canales, parte real y parte imaginaria.
- 2 Entrenar un autoencoder convolucional *denoising* para recuperar ρ a partir de una versión degradada, construida desde información marginal incompleta.
- 3 Imponer las condiciones de estado físico mediante el operador de imposición de marginales, aplicado sobre la salida de la red.

- 1 Codificar ρ como un arreglo de dos canales, parte real y parte imaginaria.
- 2 Entrenar un autoencoder convolucional *denoising* para recuperar ρ a partir de una versión degradada, construida desde información marginal incompleta.
- 3 Imponer las condiciones de estado físico mediante el operador de imposición de marginales, aplicado sobre la salida de la red.

Por qué una arquitectura convolucional

La estructura de bloques de ρ bajo particiones de subsistemas hace que las correlaciones relevantes sean locales en la representación matricial. Los pesos compartidos reducen el número de parámetros respecto de una red densa de igual capacidad.

Operador de imposición de marginales

El operador $\mathcal{M}$ proyecta la salida de la red sobre el conjunto de estados compatibles con los marginales medidos,

$$\hat{\rho} \mapsto \mathcal{M}(\hat{\rho}), \quad \text{Tr}_{\bar{S}}(\mathcal{M}(\hat{\rho})) = \rho_S.$$

Operador de imposición de marginales

El operador $\mathcal{M}$ proyecta la salida de la red sobre el conjunto de estados compatibles con los marginales medidos,

$$\hat{\rho} \mapsto \mathcal{M}(\hat{\rho}), \quad \text{Tr}_{\bar{S}}(\mathcal{M}(\hat{\rho})) = \rho_S.$$

- La salida de la red no necesita satisfacer las restricciones por sí misma.
- Las condiciones de hermiticidad, positividad y traza se garantizan por construcción, no por penalización en la función de costo.
- El operador es diferenciable, de modo que puede incluirse dentro del grafo de entrenamiento.

Diagrama: codificador convolucional, cuello de botella, decodificador, aplicación de $\mathcal{M}$ sobre la salida.

Generación de datos y entrenamiento

- Conjunto de entrenamiento generado según la medida de Hilbert-Schmidt sobre estados de N partes.
- Degradación de la entrada mediante eliminación controlada de información marginal.
- Función de costo basada en la distancia entre ρ y $\hat{\rho}$.
- Optimizador Adam, implementación en PyTorch.

Generación de datos y entrenamiento

- Conjunto de entrenamiento generado según la medida de Hilbert-Schmidt sobre estados de N partes.
- Degradación de la entrada mediante eliminación controlada de información marginal.
- Función de costo basada en la distancia entre ρ y $\hat{\rho}$.
- Optimizador Adam, implementación en PyTorch.

Métrica de evaluación

La calidad de la reconstrucción se cuantifica mediante la fidelidad

$$F(\rho, \hat{\rho}) = \left[\text{Tr} \sqrt{\sqrt{\rho} \hat{\rho} \sqrt{\rho}} \right]^2.$$

Figura: fidelidad de reconstrucción.

Figura: comparación con y sin imposición de marginales.

Figura: robustez frente a ruido.

Conclusiones del trabajo I

- La reconstrucción de estados mixtos a partir de marginales incompletos admite una solución basada en autoencoders convolucionales.

Conclusiones del trabajo I

- La reconstrucción de estados mixtos a partir de marginales incompletos admite una solución basada en autoencoders convolucionales.
- Imponer las condiciones de estado físico mediante un operador diferenciable resulta preferible a penalizarlas en la función de costo, porque las garantiza por construcción.

Conclusiones del trabajo I

- La reconstrucción de estados mixtos a partir de marginales incompletos admite una solución basada en autoencoders convolucionales.
- Imponer las condiciones de estado físico mediante un operador diferenciable resulta preferible a penalizarlas en la función de costo, porque las garantiza por construcción.
- El método opera sobre la matriz densidad directamente, lo que lo distingue de los enfoques de tomografía neuronal restringidos a estados puros.

Conclusiones del trabajo I

- La reconstrucción de estados mixtos a partir de marginales incompletos admite una solución basada en autoencoders convolucionales.
- Imponer las condiciones de estado físico mediante un operador diferenciable resulta preferible a penalizarlas en la función de costo, porque las garantiza por construcción.
- El método opera sobre la matriz densidad directamente, lo que lo distingue de los enfoques de tomografía neuronal restringidos a estados puros.

Limitaciones

Escalamiento con el número de partes, dependencia de la distribución de entrenamiento, y ausencia de garantía de unicidad cuando el conjunto de marginales no es informacionalmente completo.

Planteamiento del problema

Se busca una representación continua de $\hat{U}(t)$ generada por un Hamiltoniano dependiente del tiempo, sin recalcular la evolución para cada instante consultado.

Planteamiento del problema

Se busca una representación continua de $\hat{U}(t)$ generada por un Hamiltoniano dependiente del tiempo, sin recalcular la evolución para cada instante consultado.

- Magnus requiere evaluar conmutadores anidados en cada paso.
- Trotter requiere concatenar $n = t/\Delta t$ pasos, con n creciente al exigir mayor precisión.
- En ambos casos, el costo de obtener $\hat{U}(t)$ crece con t .

Planteamiento del problema

Se busca una representación continua de $\hat{U}(t)$ generada por un Hamiltoniano dependiente del tiempo, sin recalcular la evolución para cada instante consultado.

- Magnus requiere evaluar conmutadores anidados en cada paso.
- Trotter requiere concatenar $n = t/\Delta t$ pasos, con n creciente al exigir mayor precisión.
- En ambos casos, el costo de obtener $\hat{U}(t)$ crece con t .

Objetivo

Una representación cuyo costo de evaluación sea independiente del instante consultado.

La red toma el tiempo como entrada y devuelve los elementos de la unitaria,

$$t \longmapsto \hat{U}_\theta(t),$$

con las partes real e imaginaria como canales de salida separados.

La red toma el tiempo como entrada y devuelve los elementos de la unitaria,

$$t \longmapsto \hat{U}_\theta(t),$$

con las partes real e imaginaria como canales de salida separados.

La derivada temporal se obtiene por diferenciación automática, de modo que el residuo

$$\mathcal{L}_{\text{física}} = \sum_j \left\| i\hbar \partial_t \hat{U}_\theta(t_j) - \hat{H}_\theta(t_j) \hat{U}_\theta(t_j) \right\|^2$$

puede evaluarse en cualquier punto de colocación, sin discretización temporal.

Hamiltoniano efectivo

El objeto reconstruido es un generador efectivo, no el Hamiltoniano microscópico.

El objeto reconstruido es un generador efectivo, no el Hamiltoniano microscópico.

- Muchos Hamiltonianos distintos generan la misma dinámica sobre la ventana temporal y el conjunto de observables muestreados.
- El método no resuelve esa degeneración, y no pretende hacerlo.
- El criterio de éxito es la fidelidad de la evolución reproducida, no el error en los coeficientes.

Hamiltoniano efectivo

El objeto reconstruido es un generador efectivo, no el Hamiltoniano microscópico.

- Muchos Hamiltonianos distintos generan la misma dinámica sobre la ventana temporal y el conjunto de observables muestreados.
- El método no resuelve esa degeneración, y no pretende hacerlo.
- El criterio de éxito es la fidelidad de la evolución reproducida, no el error en los coeficientes.

Decisión de diseño

Un constraint diferenciable sobre $\partial_t \hat{U}$ acercaría los coeficientes a los del Hamiltoniano real, pero exigiría medir $\hat{U}$ en instantes muy próximos para aproximar la derivada. Se optó por no imponerlo, para mantener el algoritmo sobre información experimentalmente accesible.

Diagrama: arquitectura de la red y composición de la función de costo.

El desempeño se evalúa frente a Magnus y Trotter bajo condiciones equiparadas.

El desempeño se evalúa frente a Magnus y Trotter bajo condiciones equiparadas.

- Sistemas de 2 a 8 qubits.
- Métrica de calidad: fidelidad de la unitaria reconstruida.
- Métrica de costo: tiempo de evaluación, medido tras estabilizar la GPU.
- Distribuciones de tiempo asimétricas, reportadas mediante bandas de mínimo y máximo en lugar de desviación estándar.

Sistema	Método de referencia	Aceleración
2 a 6 qubits	Magnus y Trotter	$8,9\times$ a $19,3\times$
7 qubits	Trotter	$6,8\times$
8 qubits	Trotter	$17,8\times$
7 qubits	Magnus	$2,0\times$
8 qubits	Magnus	$7,8\times$

Resultados: aceleración

Sistema	Método de referencia	Aceleración
2 a 6 qubits	Magnus y Trotter	$8,9\times$ a $19,3\times$
7 qubits	Trotter	$6,8\times$
8 qubits	Trotter	$17,8\times$
7 qubits	Magnus	$2,0\times$
8 qubits	Magnus	$7,8\times$

La aceleración aumenta con el tamaño del sistema en ambos métodos de referencia.

Figura: fidelidad de la evolución reproducida.

Figura: costo computacional frente al tamaño del sistema.

Conclusiones del trabajo II

- Una red informada por la física proporciona una representación continua de $\hat{U}(t)$ cuyo costo de evaluación no depende del instante consultado.

Conclusiones del trabajo II

- Una red informada por la física proporciona una representación continua de $\hat{U}(t)$ cuyo costo de evaluación no depende del instante consultado.
- La aceleración frente a Magnus y Trotter se sostiene hasta 8 qubits, y crece con el tamaño del sistema.

Conclusiones del trabajo II

- Una red informada por la física proporciona una representación continua de $\hat{U}(t)$ cuyo costo de evaluación no depende del instante consultado.
- La aceleración frente a Magnus y Trotter se sostiene hasta 8 qubits, y crece con el tamaño del sistema.
- El generador reconstruido es efectivo. Reproduce la dinámica sin identificar los coeficientes del Hamiltoniano microscópico.

Conclusiones del trabajo II

- Una red informada por la física proporciona una representación continua de $\hat{U}(t)$ cuyo costo de evaluación no depende del instante consultado.
- La aceleración frente a Magnus y Trotter se sostiene hasta 8 qubits, y crece con el tamaño del sistema.
- El generador reconstruido es efectivo. Reproduce la dinámica sin identificar los coeficientes del Hamiltoniano microscópico.

Limitaciones

El entrenamiento tiene un costo inicial que solo se amortiza si la unitaria se consulta repetidamente. La validación fuera de la ventana temporal de entrenamiento acota el rango de extrapolación admisible.

- Predicción de marginales no medidos a partir del conjunto medido, en lugar de reconstrucción del estado global.

- Predicción de marginales no medidos a partir del conjunto medido, en lugar de reconstrucción del estado global.
- Incorporación de constraints diferenciables sobre $\partial_t \hat{U}$, condicionada a la disponibilidad de tomografía de proceso a alta densidad temporal.

- Predicción de marginales no medidos a partir del conjunto medido, en lugar de reconstrucción del estado global.
- Incorporación de constraints diferenciables sobre $\partial_t \hat{U}$, condicionada a la disponibilidad de tomografía de proceso a alta densidad temporal.
- Extensión de ambos métodos a dinámica no unitaria, mediante la ecuación maestra de Lindblad.

Susceptibilidad local como criterio de diseño

La susceptibilidad $\chi(x)$, definida a partir de la norma de Frobenius acumulada de los jacobianos internos, correlaciona espacialmente con el error de la red y permite asignar capacidad donde se necesita. Su extensión a circuitos cuánticos variacionales es la continuación natural de esta tesis.

Susceptibilidad local como criterio de diseño

La susceptibilidad $\chi(x)$, definida a partir de la norma de Frobenius acumulada de los jacobianos internos, correlaciona espacialmente con el error de la red y permite asignar capacidad donde se necesita. Su extensión a circuitos cuánticos variacionales es la continuación natural de esta tesis.

- Tomografía dinámica de estados cuánticos.
- Aprendizaje sobre circuitos variacionales.
- Diagnóstico de arquitecturas mediante susceptibilidades.

- Uzcátegui-Contreras *et al.*, reconstrucción de matrices densidad mediante imposición de marginales. Publicado.
- Guerra *et al.*, *Interpolation of unitaries with time-dependent Hamiltonians via Deep Learning*. En evaluación, *Machine Learning: Science and Technology*.
- Muñoz-Mellado *et al.*, *Entanglement and discord classification via deep learning*. En preparación.
- Susceptibilidad local $\chi(x)$ como criterio de diagnóstico y diseño en PINNs. En preparación.

Gracias

Antonio Guerra
Universidad de Concepción

Respaldo: por qué un Hamiltoniano efectivo y no el real

- La literatura de Hamiltonian learning mide éxito como error paramétrico bajo un ansatz fijo. Si el Hamiltoniano verdadero no pertenece al espacio generado por esa base, lo recuperado es también un generador efectivo.
- La degeneración es intrínseca: distintos generadores producen la misma dinámica sobre la ventana temporal y el conjunto de observables muestreados.
- La validación se hace fuera de la ventana de entrenamiento, no por identificación de coeficientes.

- Un término $\|\partial_t \hat{U} - f(\hat{H}, \hat{U})\|^2$ acercaría los coeficientes a los del Hamiltoniano real.
- Obtener la referencia exige medir $\hat{U}$ en instantes separados por δ pequeño, y la resta de dos cantidades ruidosas dividida por δ amplifica el error.
- La decisión de no incluirlo mantiene el método sobre información experimentalmente accesible. Queda identificado como extensión.

Respaldo: unicidad de la reconstrucción desde marginales

- Cuando $\mathcal{S}$ no es informacionalmente completo, existen múltiples ρ compatibles.
- El operador de imposición garantiza compatibilidad con los marginales medidos, no unicidad.
- La red selecciona, dentro del conjunto compatible, el estado más cercano a la distribución de entrenamiento.

Respaldo: costo de entrenamiento frente a costo de evaluación

- La aceleración reportada corresponde a la fase de evaluación.
- El entrenamiento tiene un costo inicial que debe amortizarse.
- El punto de equilibrio depende del número de instantes consultados.