

Deep Learning para problemas de información cuántica

Defensa de Tesis Doctoral — *demo Typst + Touying*

Antonio Guerra

2026-07-07

Universidad de Concepción

1. **Background** — información cuántica y deep learning
2. **Estado del arte** — combinando ambos mundos
3. **Contribución 1** — interpolación de unitarias (PINNs)
4. **Contribución 2** — reconstrucción desde marginales (CDAE + MIO)
5. **Conclusiones** y trabajo futuro

Idea rectora. Incrustar la física conocida en el aprendizaje (*physics-informed*) extiende los métodos clásicos a problemas cuya complejidad crece como 2^N .

Background: la barrera exponencial

Un estado de N qubits vive en un espacio de dimensión 2^N :

$$\rho(t) = U(t)\rho_0 U^\dagger(t), \quad i\dot{U} = H(t)U.$$

- Construir/exponenciar $U(t)$ escala como $\mathcal{O}(2^{3N})$.
- Con $H(t)$ dependiente del tiempo no hay e^{-iHt} cerrado.


Physics-informed learning. La física entra por la *loss*: la red aprende solo soluciones físicamente admisibles (unitaridad, positividad, marginales).

Contribución 1 — Interpolación de unitarias con PINNs

Dada $U(t_i)$ en tiempos muestreados, interpolamos $U(t)$ en todo $[0, T]$ **sin conocer el Hamiltoniano**.

$$F(U, U_\theta) = \left| \frac{1}{d} \text{Tr}[U^\dagger U_\theta] \right|^2$$


- Fidelidad ≈ 0.99 (2–8 qubits)
- Speedups $8.9 \times - 19.3 \times$ vs. geodésica



Contribución 2 — Reconstrucción desde marginales (CDAE + MIO)

El *Quantum Marginal Problem* (QMA-completo): dado $\{\sigma_{\mathcal{J}}\}$, reconstruir un estado global ρ compatible.

- Matriz de densidad $\rightarrow$ imagen de 2 canales
- CDAE + MIO $\rightarrow$ estado físico válido
- **Transfer learning** de 3 a 8 qubits
- Más rápido que SDP (resuelve donde SDP falla)



Dos problemas duros, un mismo patrón:
la física en la loss convierte lo intratable en aprendible.