

Resumen tesis Antonio Guerra

Uso de redes neuronales para el estudio de sistemas físicos aplicables a Información Cuántica

Esta tesis explora el uso de técnicas de Deep Learning para modelar y resolver problemas fundamentales en el área de la Información Cuántica, con énfasis en sistemas de múltiples qubits y su dinámica. El trabajo se estructura en dos líneas principales: la reconstrucción de estados cuánticos a partir de información parcial y el aprendizaje de la evolución temporal de sistemas gobernados por Hamiltonianos dependientes del tiempo.

En una primera etapa, se aborda el problema de los marginales cuánticos, que consiste en determinar si un conjunto de matrices densidad reducidas es compatible con un estado global. Este problema es conocido por su alta complejidad computacional (QMA-completo). Para enfrentarlo, se desarrolló un enfoque basado en convolutional denoising autoencoder que, combinado con técnicas de imposición de marginales, permite reconstruir matrices densidad físicas (hermíticas, positivas y normalizadas) a partir de sus marginales. Los resultados muestran altas fidelidades y tasas de éxito, además de una reducción significativa en el costo computacional en comparación con métodos tradicionales basados en programación semidefinida [1].

En una segunda etapa, se estudia el problema de la dinámica cuántica en sistemas gobernados por Hamiltonianos dependientes del tiempo, donde el objetivo es estimar el operador unitario de evolución. Para ello, se propone un enfoque basado en Physics-Informed Neural Networks (PINNs) que incorpora directamente restricciones físicas, como la unitariedad y la ecuación de von Neumann, dentro del proceso de entrenamiento. El modelo permite aprender la evolución temporal completa a partir de un número reducido de muestras, logrando altas fidelidades incluso en sistemas de hasta 8 qubits. Un resultado clave es la capacidad de los modelos para interpolar dinámicas cuánticas con alta precisión, incluso cuando los datos de entrenamiento son escasos o están discretizados de forma gruesa [2]. Además, se propone una estrategia híbrida para sistemas de mayor dimensión, en la que la red neuronal aprende un Hamiltoniano efectivo, reduciendo significativamente la complejidad del problema.

En conjunto, esta tesis demuestra que los modelos de Machine Learning, cuando incorporan conocimiento físico del sistema, pueden transformarse en herramientas altamente eficientes para la simulación, reconstrucción y comprensión de sistemas cuánticos complejos. Estos resultados abren nuevas oportunidades para aplicaciones en computación cuántica, control cuántico y simulación de sistemas de muchos cuerpos.

[1] Uzcategui-Contreras, D. et al. (2025). Machine learning approach to reconstruct density matrices from quantum marginals. Machine Learning: Science and Technology.

[2] Guerra, A. et al. (2026). Interpolation of unitaries with time-dependent Hamiltonians via deep learning. arXiv.